
RESUMEN DE ARTÍCULOS Y CONVERGENCIA EN AUTOCORRELACIÓN ESPACIAL

October 7, 2025

1 Artículo 1: Vegetación en Yinshan Mountains, China

Referencia

Yan et al. (2025). Remote sensing evidence on marginality, stagementation and spatiotemporal heterogeneity of vegetation evolution characteristics in Yinshan Mountains, China. *Ecological Indicators*, 171, 113193

1.1 Resumen

El estudio de Yan y su equipo (2025) ofrece una mirada profunda al comportamiento de la vegetación en ecosistemas frágiles, utilizando herramientas de teledetección de última generación. El escenario de esta investigación son las montañas Yinshan, en el corazón de China: un territorio árido, de belleza severa, donde las estepas luchan contra la desertificación en una batalla silenciosa que lleva décadas.

Para entender esa larga historia vegetal, los investigadores recurrieron a una serie temporal del índice NDVI del conjunto PKU GIMMS, que abarca casi cuarenta años (1984–2022). Esta mirada prolongada en el tiempo permitió seguir el pulso verde de la región —sus avances, retrocesos y resistencias— con una precisión inédita.

Las Yinshan, situadas en una zona árida y semiárida, son un observatorio natural privilegiado para estudiar cómo los ecosistemas responden a los vaivenes del clima y a la huella humana. Allí, cada milímetro de lluvia, cada cambio en el uso del suelo, deja marcas visibles, casi como si el paisaje mismo llevara un diario ecológico. Y es precisamente en esas huellas donde el equipo de Yan buscó respuestas: ¿cómo cambian los patrones vegetales a lo largo del tiempo? ¿Y cuáles son las fuerzas que los moldean?

1.2 Aplicación de Autocorrelación Espacial

Para descifrar esas dinámicas, los autores aplicaron un conjunto de métodos estadísticos avanzados. Comenzaron con el análisis Theil-Sen y la prueba Mann-Kendall, herramientas que permiten detectar tendencias en los valores del NDVI sin asumir comportamientos estadísticos ideales (algo especialmente útil en datos ambientales llenos de variaciones extremas).

Luego añadieron el Índice de Hurst, una medida fascinante que evalúa si las tendencias detectadas son sostenibles o meramente pasajeras. En otras palabras: si la vegetación de Yinshan sigue un patrón persistente, o si solo responde con impulsos breves a los caprichos del clima.

Pero el verdadero punto de innovación fue el uso de la autocorrelación bivariada espacial (Bi-SA). Esta técnica, que examina la relación espacial entre dos variables distintas —en este caso, el NDVI y los factores climáticos— permitió identificar no solo dónde cambia la vegetación, sino también por qué.

El núcleo del análisis se apoyó en el Índice de Moran (Moran's I), que reveló un hallazgo contundente: la vegetación muestra una correlación espacial extraordinariamente alta con la precipitación ($P < 0.01$). En términos más claros, las zonas donde la vegetación responde de manera similar a la lluvia tienden a agruparse, formando patrones coherentes a gran escala. Esta organización espacial sugiere que detrás de los cambios visibles operan procesos ecológicos profundos, que trascienden los límites locales y conectan el paisaje en una red viva de interdependencias.

1.3 Hallazgos Principales

Yan et al. descubren que la vegetación de las montañas Yinshan presenta una distribución heterogénea y escalonada del sureste al noroeste, moldeada por gradientes ambientales como la altitud, el viento y la disponibilidad de agua.

En el tiempo, la dinámica vegetal sigue un patrón “estable-caída-aumento”, reflejando fases de estabilidad, de-

clive por estrés ambiental y posterior recuperación. Esto evidencia la resiliencia de los ecosistemas esteparios, aunque también su vulnerabilidad ante perturbaciones.

El clima muestra una tendencia hacia condiciones más cálidas y húmedas, con un aumento anual de 0.045 °C en temperatura y 0.558 mm en precipitación. Aunque parecen cambios leves, acumulados por décadas implican transformaciones significativas.

La precipitación emerge como el factor limitante principal, con una fuerte correlación espacial entre la lluvia y el crecimiento vegetal. En contraste, la influencia humana resulta débil, lo que indica que en esta región el clima domina sobre las actividades antropogénicas en la dinámica de la vegetación.

2 Artículo 2: Exposición Costera al Aumento del Nivel del Mar en Marruecos

Referencia

Lamhadri et al. (2025). Assessing coastal exposure to Sea Level Rise: a coupled approach of qualitative modeling and spatial autocorrelation analysis *Natural Hazard Research* (preprint).

2.1 Resumen

Lamhadri y colaboradores (2025) analizan el riesgo del aumento del nivel del mar en un tramo de 25 km de la costa atlántica de Marruecos, específicamente en Salé, una zona densamente poblada, económicamente relevante y geomorfológicamente vulnerable.

El estudio combina el modelo InVEST, usado para evaluar servicios ecosistémicos, con análisis de autocorrelación espacial, una integración que permite simular escenarios de exposición costera y revelar patrones espaciales de vulnerabilidad que no serían visibles mediante métodos tradicionales.

2.2 Aplicación de Autocorrelación Espacial

2.2.1 Índice Global de Moran (I)

El Índice Global de Moran es el eje central del análisis de autocorrelación espacial del estudio, ya que mide cuantitativamente la correlación espacial del Índice de Exposición (EI) a lo largo de la costa analizada. Permite evaluar en qué grado los valores del EI en un punto se relacionan con los de sus áreas vecinas, ofreciendo una visión general de la estructura espacial de la vulnerabilidad costera.

Sus valores van de -1 a 1, los positivos indican agrupamiento espacial (valores similares tienden a concentrarse), los cercanos a 0 reflejan distribución aleatoria, y los negativos —menos comunes en fenómenos naturales— señalan dispersión, donde valores altos están rodeados de

bajos y viceversa. La fórmula matemática del índice se expresa como:

$$I = \frac{n \sum_{i=1}^n \sum_{j=1}^n w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_{i=1}^n \sum_{j=1}^n w_{ij} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (1)$$

donde n representa el número de unidades espaciales analizadas, x_i y x_j son los valores de la variable de interés en las ubicaciones i y j , \bar{x} es la media de la variable, y w_{ij} son los elementos de la matriz de pesos espaciales que definen la estructura de vecindad entre ubicaciones.

2.2.2 LISA (Local Indicators of Spatial Association)

Mientras el Índice Global de Moran ofrece una visión general de la autocorrelación espacial, los Indicadores Locales de Asociación Espacial (LISA) permiten descomponer esa medida y detectar dónde surgen los clusters y outliers en el territorio. Esta capacidad de distinguir la heterogeneidad espacial local es clave para orientar estrategias de adaptación y gestión costera, concentrando los esfuerzos en las zonas más vulnerables.

El análisis LISA clasifica cada punto en cuatro patrones principales:

- **High-High (HH):** áreas de alta exposición rodeadas de alta exposición — zonas críticas que requieren atención prioritaria.
- **Low-Low (LL):** áreas de baja exposición rodeadas de baja exposición — zonas relativamente seguras.
- **High-Low (HL):** focos aislados de alta exposición dentro de áreas generalmente bajas.
- **Low-High (LH):** puntos de baja exposición en medio de entornos de alta exposición.

La fórmula del Índice Local se expresa como:

$$I_{Local} = \frac{(x_i^p - \bar{x}^p)}{S^p} \sum_{j=1}^n w_{ij} \left(\frac{x_j^q - \bar{x}^q}{S^q} \right) \quad (2)$$

donde S^p y S^q representan las desviaciones estándar de las variables en las ubicaciones p y q .

2.2.3 Getis-Ord G_i^* (Análisis de Hotspots)

El estadístico Getis-Ord G_i^* complementa el análisis LISA al ofrecer otra vía para detectar hotspots y coldspots significativos. A diferencia de LISA —que compara cada punto con la media global—, el G_i^* evalúa si la suma de valores de una ubicación y sus vecinos difiere significativamente de lo esperado bajo un patrón aleatorio. Cada punto obtiene un valor Z estandarizado:

- $Z > 1.96$ ($p < 0.05$): identifica *hotspots*, zonas con alta exposición significativa.

- $Z < -1.96$; marca *coldspots*, áreas con concentraciones bajas.

Esta técnica es clave para detectar áreas críticas que requieren medidas de adaptación urgentes.

2.3 Hallazgos Principales

El análisis mostró un Moran's $I = 0.399$ con alta significancia ($p < 0.001$), evidenciando una fuerte dependencia espacial en la exposición costera: las áreas de alta o baja exposición tienden a agruparse, no se distribuyen al azar.

El análisis LISA reveló patrones espaciales claros. Los clusters High-High (HH) se concentraron en el oeste (provincias como Qinghai, Tíbet, Yunnan y Guangxi), representando zonas de alta vulnerabilidad. En contraste, los Low-Low (LL) se localizaron en el noreste, especialmente en Jilin, indicando áreas de exposición baja y estable. Los escenarios de hábitat mostraron el papel crucial de los ecosistemas costeros:

- **Con protección de hábitat:** 51.3% con exposición moderada y 30.4% con exposición alta.
- **Sin protección:** 56.9% con exposición alta y 31.5% con exposición muy alta.

3 Artículo 3: Incidencia de Parotiditis en China

Referencia

Hu et al. (2025). Spatial stratified heterogeneity of mumps incidence in China: a Geodetector-based analysis of driving factors. *Frontiers in Public Health*, 13, 1637288.

3.1 Resumen

El estudio de Hu et al. (2025) analiza los patrones espaciales de la parotiditis (paperas) en China aplicando el método Geodetector, diseñado para detectar y cuantificar la heterogeneidad espacial estratificada. Se examinaron datos de las 31 provincias chinas durante 2020, un año marcado por los cambios en movilidad y contacto social derivados del COVID-19.

Aunque existen vacunas eficaces y programas de inmunización, la parotiditis sigue siendo un problema de salud pública con brotes persistentes y variaciones geográficas notables. Esto sugiere que factores biológicos, socioeconómicos y ambientales interactúan de manera compleja, y que entender esta variabilidad es clave para optimizar las estrategias de prevención y asignación de recursos.

3.2 Aplicación de Autocorrelación Espacial

3.2.1 Moran's I Global

El Índice Global de Moran registró un valor de 0.399 ($p < 0.001$), indicando clustering espacial significativo en

la incidencia de parotiditis a nivel provincial. Este valor positivo y moderado muestra que las provincias con tasas similares tienden a agruparse geográficamente, reflejando procesos de transmisión a gran escala o factores de riesgo compartidos.

En términos de salud pública, esto subraya que el control de la enfermedad no puede abordarse provincia por provincia: es esencial considerar la influencia de las regiones vecinas y diseñar políticas coordinadas que aborden la difusión espacial del contagio.

3.2.2 LISA Cluster Maps

El análisis LISA identificó patrones espaciales locales muy reveladores. Los clusters High-High se concentraron en el oeste de China —provincias como Qinghai, Tibet, Yunnan y Guangxi—, zonas donde varias provincias vecinas registran altas tasas de parotiditis simultáneamente. Estos hotspots sugieren la presencia de condiciones locales que favorecen la transmisión, como baja cobertura vacunal, densidad poblacional elevada, factores socioeconómicos o climas específicos.

Por contraste, los clusters Low-Low aparecieron en el noreste, especialmente en Jilin, donde tanto la provincia como sus vecinas mantienen baja incidencia, reflejando éxito en el control de la enfermedad. Analizar estas zonas podría ofrecer lecciones útiles sobre estrategias efectivas replicables en otras regiones.

Finalmente, el estudio evidenció un gradiente espacial oeste-este, con una disminución progresiva en la incidencia. Este patrón apunta a factores estructurales —desarrollo económico, acceso sanitario y diferencias culturales en la prevención— que varían sistemáticamente a lo largo del país.

3.2.3 G_i^* Cluster Maps

El análisis Getis-Ord G_i^* confirmó y amplió los resultados del LISA, al identificar hotspots significativos en el oeste de China, con niveles de confianza del 90–99 %. Estas zonas concentran los mayores casos de parotiditis y requieren intervenciones prioritarias. A su vez, se detectaron coldspots en el noreste, con niveles de confianza similares, lo que evidencia un contraste espacial marcado entre las regiones occidental y oriental del país.

3.3 Método Geodetector

Una de las aportaciones clave del estudio fue combinar el análisis espacial con el método Geodetector, que cuantifica la contribución de distintos factores a la heterogeneidad espacial observada. Su principio es simple pero poderoso: si un factor influye realmente en la distribución de una variable, sus patrones espaciales deberían coincidir.

3.3.1 Factor Detector: Poder Explicativo de Cada Factor

El componente de detección de factores evaluó el *poder explicativo* (PD) de cada variable potencial.

- El **ratio de dependencia infantil** fue el factor más influyente ($PD = 0.54$), coherente con la naturaleza de la parotiditis, que afecta principalmente a niños y adolescentes.
- En contraste, la **densidad de centros de salud comunitarios** presentó el poder más bajo ($PD = 0.31$), lo que sugiere que la infraestructura sanitaria por sí sola no basta: la calidad del servicio, la cobertura vacunal y el uso real de la atención médica tienen un mayor peso que la cantidad de establecimientos.

3.3.2 Detector de Interacción: Efectos Sinérgicos entre Factores

El análisis *Geodetector* reveló fuertes efectos sinérgicos entre los factores estudiados. Este detector evalúa si dos variables combinadas explican más variabilidad que la suma de sus efectos individuales.

La interacción entre el **PIB per cápita** y la **tasa de analfabetismo** mostró el mayor poder explicativo ($PD = 0.88$), muy superior al de cada factor por separado, evidenciando que el desarrollo económico y la educación actúan de forma sinérgica en el riesgo de parotiditis.

Además, todas las combinaciones de factores mostraron efectos de mejora o no lineales, con valores de $PD > 0.5$, lo que confirma que la enfermedad está influida por una red compleja de interacciones. Por ello, las estrategias más eficaces deberán abordar múltiples determinantes simultáneamente, en lugar de factores aislados.

3.4 Hallazgos Principales

El estudio presenta un panorama complejo y espacialmente estructurado de la parotiditis en China. Se confirma un gradiente oeste-este decreciente en la incidencia, asociado con diferencias en desarrollo socioeconómico, acceso sanitario y cobertura vacunal.

El valor de Moran's $I = 0.399$ ($p < 0.001$) ratifica la fuerte agrupación espacial, señalando que la transmisión no puede analizarse sin considerar la dimensión geográfica. El **ratio de dependencia infantil** fue el factor individual más asociado a la incidencia, destacando la importancia de la estructura demográfica en el riesgo de enfermedad.

Los **recursos sanitarios**, en cambio, mostraron una influencia débil al considerarse aisladamente, lo que sugiere que la calidad y cobertura de los servicios pesan más que la mera cantidad de infraestructuras. Finalmente, los **efectos sinérgicos entre variables** confirman que la parotiditis tiene una causalidad múltiple, y que su control exige enfoques integrados y multisectoriales.

4 Convergencia y Definición de Autocorrelación Espacial

4.1 Definición

La autocorrelación espacial es un concepto central en el análisis espacial y la geografía cuantitativa. Permite medir y describir cómo se relacionan los valores de una variable con los de sus vecinos geográficos, es decir, si los valores similares tienden a agruparse o se distribuyen aleatoriamente.

Muchos fenómenos naturales y sociales presentan estructuras espaciales no aleatorias, donde los valores de una variable en un punto son más parecidos a los de ubicaciones cercanas que a los de lugares distantes. Esta dependencia espacial refleja procesos como la difusión, la dispersión, las interacciones locales o gradientes ambientales que cambian de forma continua en el espacio.

4.2 Principio Fundamental: Primera Ley de Geografía de Tobler (1970)

El principio de la autocorrelación espacial se sintetiza magistralmente en la Primera Ley de Geografía de Waldo Tobler (1970):

“Todo está relacionado con todo lo demás, pero las cosas cercanas están más relacionadas que las cosas distantes.”

Esta afirmación, simple pero profunda, explica cómo la proximidad espacial refuerza las relaciones entre fenómenos. Reconoce la interconexión universal del mundo, pero subraya que la distancia modula la intensidad de esas relaciones.

Sus implicaciones son amplias: en el plano metodológico, advierte que los modelos estadísticos tradicionales —que asumen independencia entre observaciones— pueden fallar con datos espaciales; y en el plano conceptual, invita a los investigadores a integrar la dimensión espacial como un elemento esencial que influye en la forma y dinámica de los procesos observados.

4.3 Tipos de Autocorrelación Espacial

La autocorrelación espacial puede adoptar distintas formas, con efectos teóricos y prácticos diversos. Su clasificación se basa principalmente en el Índice de Moran, el indicador más común para medir el grado de relación espacial entre valores de una variable.

Table 1: Tipos de autocorrelación espacial según el valor del Índice de Moran

Tipo	Interpretación y Ejemplo
Positiva ($0 < I \leq 1$)	Indica clustering de valores similares; áreas con valores altos rodeadas de altas (HH) o bajas rodeadas de bajas (LL).
Negativa ($-1 \leq I < 0$)	Señala dispersión espacial de valores disímiles; patrón tipo “tablero de ajedrez” donde los altos se rodean de bajos y viceversa.
Aleatoria ($I \approx 0$)	No existe patrón espacial aparente; los valores se distribuyen de manera aleatoria en el espacio.

La autocorrelación espacial positiva (Moran's I entre 0 y 1) refleja clustering espacial, donde valores altos se agrupan con otros altos (High-High) y los bajos con bajos (Low-Low). Es el patrón más común en fenómenos naturales y sociales, asociado a procesos como difusión, efectos de derrame o variaciones contextuales suaves. Cuanto más cercano a 1 es el índice, más fuerte es el agrupamiento.

La autocorrelación negativa (Moran's -1 y 0) indica dispersión espacial, con valores altos rodeados de bajos y viceversa, similar a un tablero de ajedrez. Surge en procesos de competencia espacial, como territorios de especies rivales o negocios que compiten por la misma clientela.

Finalmente, cuando *Moran's* $I \approx 0$, no existe autocorrelación espacial: los valores se distribuyen de manera aleatoria y no guardan relación con los de sus vecinos. Este patrón es poco común y puede deberse a procesos verdaderamente aleatorios o a que la escala de análisis no logra capturar los procesos espaciales relevantes.

4.4 Convergencia entre los Tres Estudios

El análisis comparativo de los tres trabajos muestra una convergencia sólida tanto en lo metodológico como en lo conceptual, reflejando la madurez del análisis espacial aplicado a ámbitos ambientales, epidemiológicos y de gestión del riesgo. Esta coincidencia evidencia un paradigma común que reconoce la importancia de la estructura espacial para entender fenómenos complejos.

4.4.1 Metodología Común

Los tres estudios comparten herramientas clave del análisis espacial contemporáneo:

- **Índice Global de Moran:** detecta y cuantifica la dependencia espacial general, ofreciendo una medida robusta y comparable entre contextos.
- **LISA (Local Indicators of Spatial Association):** descompone la autocorrelación global en patrones locales —High-High, Low-Low, High-Low y

Low-High—, identificando la localización de los *clusters*.

- **Getis-Ord (G_i^*):** localiza *hotspots* y *coldspots* con significancia estadística, complementando al LISA y destacando áreas prioritarias para la gestión.

4.4.2 Objetivo Compartido

Más allá de la coincidencia metodológica, los tres estudios persiguen objetivos analíticos comunes. En primer lugar, buscan detectar patrones espaciales no aleatorios, es decir, determinar si la distribución de la variable —ya sea cobertura vegetal, exposición costera o incidencia de enfermedad— presenta estructura espacial significativa.

El segundo objetivo es localizar con precisión las áreas de alta o baja concentración, proporcionando información práctica para dirigir recursos y estrategias hacia zonas prioritarias.

Finalmente, todos comparten un propósito explicativo: comprender los mecanismos que generan los patrones observados. No se limitan a describir el “dónde”, sino que intentan explicar el “por qué”, conectando el análisis espacial con teorías sustantivas en cada campo.

4.4.3 Hallazgos Similares

Pese a sus distintos contextos, los tres estudios reportan clustering espacial significativo, con valores de Moran's $I > 0.3$ y alta significancia estadística ($p < 0.01$). Esta consistencia empírica valida la Primera Ley de Geografía de Tobler, confirmando que los fenómenos naturales y sociales tienden a agruparse espacialmente.

En todos los casos predominan los patrones High-High y Low-Low, lo que indica que los valores similares tienden a concentrarse más que a dispersarse, reflejando procesos de difusión y efectos de derrame. Asimismo, cada estudio subraya la influencia de factores contextuales locales —clima, topografía, ecosistemas o variables socioeconómicas— como impulsores directos de la estructura espacial observada.

4.4.4 Complementariedad

Cada estudio aporta una innovación clave. El análisis sobre vegetación en Yinshan introduce la autocorrelación bivariada (Bi-SA), explorando la relación espacial entre el NDVI y variables climáticas. El de exposición costera en Marruecos aplica la autocorrelación a un índice compuesto derivado del modelo InVEST, demostrando su utilidad en la evaluación de políticas mediante escenarios con y sin protección de hábitats. Finalmente, el estudio sobre parotiditis en China combina la autocorrelación con el método Geodetector, cuantificando la contribución e interacción de factores y elevando el análisis espacial a una dimensión explicativa más profunda.

4.5 Ventajas de Combinar Autocorrelación Espacial con Otros Métodos

Combinar el análisis de autocorrelación espacial con otras herramientas —modelos ecológicos, simulaciones o análisis causales— ofrece una visión más completa y sinérgica de los fenómenos complejos. Esta convergencia metodológica permite captar simultáneamente patrones, procesos y causas, fortaleciendo la comprensión científica y la capacidad de diseñar estrategias de intervención más efectivas.

Table 2: Ventajas de integración metodológica con análisis de autocorrelación espacial (versión compacta)

Método	Ventaja de Integración
Regresión	Corrige el sesgo derivado de la dependencia espacial mediante modelos espaciales (lag, error), que ajustan la autocorrelación y mejoran la validez de las estimaciones.
Geodetector	Cuantifica la contribución e interacción de factores en la heterogeneidad espacial, permitiendo priorizar variables más influyentes.
Machine Learning	Mejora la precisión predictiva al incorporar variables espaciales (lags, vecindad) que capturan la dependencia entre observaciones.
Análisis Temporal	Revela dinámicas espacio-temporales, mostrando cómo evolucionan los patrones espaciales a lo largo del tiempo.

Combinar la autocorrelación espacial con modelos de regresión es esencial: la dependencia espacial viola el supuesto de independencia, generando sesgos y errores. Los modelos de regresión espacial corrigen esto al incluir términos de lag o error espacial, permitiendo además medir efectos de spillover, donde los cambios en una zona afectan a sus vecinas.

La unión con el método Geodetector —como en el estudio sobre parotiditis— refuerza el análisis: la autocorrelación

detecta dónde hay heterogeneidad, y el Geodetector explica por qué, cuantificando factores e interacciones no lineales. Este enfoque combina la detección de patrones con la explicación de sus causas.

La integración en modelos de machine learning (random forests, boosting, redes neuronales) añade una dimensión innovadora. Al incluir características espaciales —lags, vecindad o embeddings— se mejora el rendimiento predictivo y se incorpora la estructura espacial que los algoritmos clásicos ignoran.

Por último, la fusión de dimensiones espaciales y temporales permite estudiar cómo los patrones cambian y persisten en el tiempo. El estudio sobre vegetación en las montañas Yinshan ejemplifica esta integración, combinando Theil-Sen, Mann-Kendall, el Índice de Hurst y autocorrelación espacial para describir la dinámica espacio-temporal del ecosistema.

4.6 Conclusión

La revisión de los tres estudios demuestra la **madurez** y **versatilidad** del análisis de autocorrelación espacial en campos como la ecología, la gestión costera y la epidemiología. La convergencia metodológica —basada en el **Índice de Moran**, los análisis **LISA** y los **estadísticos Getis-Ord** (G_i^*)— evidencia un conjunto de herramientas estándar, sólidas y aplicables en diversos contextos.

Los hallazgos coinciden en una **autocorrelación espacial positiva significativa**, validando la **Primera Ley de Geografía de Tobler** y resaltando la necesidad de incluir explícitamente la dimensión espacial en todo análisis con datos georreferenciados.

Las innovaciones de cada estudio —autocorrelación bivariada, análisis de escenarios e integración con **Geodetector**— muestran la **flexibilidad del marco espacial** para abordar diferentes preguntas de investigación.

Hacia el futuro, la integración con **machine learning espacial**, **big data geoespacial** y **modelado espacio-temporal** ampliará las posibilidades de comprensión de la organización espacial de fenómenos complejos, confirmando el potencial transformador de **pensar espacialmente**.